

Sales Forecasting

Bộ câu hỏi ôn tập cuối dự án

Domain	AI Projects
Project	Retail & E-Commerce — Sales Forecasting với LightGBM & SHAP
Phiên bản	Bộ câu hỏi
Thời lượng	90 phút
Tổng điểm	100 điểm

Tài liệu được phép sử dụng: tài liệu AIVN, các bài học trên website TorchViz và Google Search. Không nên sử dụng công cụ AI như ChatGPT trong lúc làm bài; hãy dành thời gian tự suy nghĩ, kết nối kiến thức và trình bày lập luận của mình.

PHẦN A — BỘ CÂU HỎI

Câu mở đầu — Cần thu thập dữ liệu gì?

Nếu doanh nghiệp chỉ đưa ra yêu cầu “hãy dự báo doanh thu”, bạn sẽ đề xuất thu thập những dữ liệu nào? Với mỗi nhóm dữ liệu, hãy cho biết dữ liệu đó có sẵn trước ngày dự báo hay chỉ xuất hiện sau khi hoạt động bán hàng xảy ra.

Câu 1 — Định nghĩa bài toán dự báo (6 điểm)

Doanh nghiệp cần phát hành kế hoạch doanh thu cho ngày (d) trước 28 ngày.

- 1. Hãy định nghĩa target, forecast horizon và information cutoff.
- 2. Phân biệt dữ liệu lịch sử với dữ liệu ngoại sinh biết trước.

Câu 2 — Feature nào được phép sử dụng? (10 điểm)

Với (H=28), hãy đánh giá từng feature sau là hợp lệ hay gây leakage khi dự báo ngày (d):

- 1. Revenue tại (d-7).
- 2. Revenue tại (d-28).
- 3. Trung bình Revenue từ (d-55) đến (d-28).
- 4. COGS thực tế của ngày (d).
- 5. Thứ trong tuần của ngày (d).
- 6. Chương trình khuyến mãi ngày (d), đã được doanh nghiệp phê duyệt trước lúc phát hành dự báo.

Với mỗi feature, hãy nêu lý do dựa trên thông tin hệ thống biết tại thời điểm dự báo.

Câu 3 — Kiểm tra dữ liệu thô (8 điểm)

Bạn nhận hai tệp có cấu trúc sau:

Tệp	Cột	Ý nghĩa
sales.csv	Date	Ngày ghi nhận doanh thu; có thể dùng yyyy-mm-dd, dd/mm/yyyy hoặc kèm giờ 00:00:00.
sales.csv	Revenue	Doanh thu trong ngày; một số giá trị có dấu phẩy phân cách hàng nghìn.
sales.csv	COGS	Giá vốn hàng bán trong ngày; một số giá trị có dấu phẩy phân cách hàng nghìn.
promotions.csv	start_date	Ngày bắt đầu chương trình khuyến mãi.
promotions.csv	end_date	Ngày kết thúc chương trình khuyến mãi.
promotions.csv	discount_value	Mức giảm giá của chương trình.
promotions.csv	applicable_category	Nhóm hàng được áp dụng khuyến mãi.

Hãy nêu các kiểm tra cần thực hiện cho từng tệp trước khi EDA:

- Mỗi cột cần được chuyển sang kiểu dữ liệu nào?
- Khoảng ngày khuyến mãi cần thỏa mãn điều kiện gì?
- Làm thế nào để phát hiện ngày bán hàng bị trùng hoặc bị thiếu?
- Cần kiểm tra giá trị thiếu và giá trị bất hợp lý ở những cột nào?
- Điều kiện nào xác nhận hai tệp đã sẵn sàng cho EDA và join dữ liệu?

Câu 4 — Xử lý ngày bị trùng (6 điểm)

Tệp thô có 3.851 dòng. Audit phát hiện 18 ngày bị ghi trùng và hai dòng của mỗi ngày trùng giống hệt nhau. Bạn sẽ:

1. Cộng hai dòng.
2. Lấy trung bình.
3. Giữ một dòng.
4. Xóa cả hai dòng rồi nội suy.

Chọn phương án, giải thích vì sao, và nêu kết quả cấu trúc dữ liệu mong đợi sau xử lý.

Câu 5 — Dự án phát hiện doanh thu bất thường bằng cách nào? (2 điểm)

Để tìm các ngày có Revenue cao hoặc thấp bất thường, dự án đã dùng phương pháp nào? Phương pháp đó dựa trên các đại lượng nào của phân phối dữ liệu?

Câu 6 — Có nên xóa các ngày doanh thu bất thường? (6 điểm)

Phương pháp trong dự án phát hiện 169 ngày doanh thu cao bất thường; 63,9% trong số đó nằm quanh thời điểm giao tháng.

1. Có nên **winsorize** — tức là thay các giá trị vượt ngưỡng bằng chính giá trị tại ngưỡng để giảm ảnh hưởng của chúng — hoặc xóa toàn bộ các ngày này không?
2. EDA nào cần thực hiện tiếp?
3. Insight này nên được chuyển thành feature như thế nào?

Câu 7 — Tạo feature mà không làm lộ dữ liệu tương lai (10 điểm)

1. **Lag là gì?** Dự án dùng lag để cung cấp thông tin nào cho model? Hãy minh họa bằng `lag_28` khi dự báo Revenue ngày 29/01/2022.
2. **Khai triển Fourier là gì?** Dự án biến ngày trong năm thành các feature Fourier để làm gì? Hãy minh họa bằng một cặp feature `sin-cos` và giải thích vì sao cách biểu diễn này phù hợp hơn chỉ dùng số thứ tự ngày trong năm.
3. Hãy thiết kế các nhóm feature cho bài toán ($H=28$), bao gồm:
 - Lag và rolling statistics.
 - Calendar và vị trí quanh cuối tháng.
 - Seasonality theo năm.
 - Tết và promotion.

4. Giải thích:

- Vì sao pipeline dùng nền `safe = y.shift(28)`.
- Feature `lag_371` cần Revenue của 371 ngày trước. Điều gì xảy ra với 371 ngày đầu tiên của chuỗi, và vì sao project không đưa các dòng này vào bảng huấn luyện?
- Vì sao COGS cùng ngày target phải bị loại dù tương quan với Revenue rất cao.
- Việc loại COGS cùng ngày có đồng nghĩa phải bỏ toàn bộ dữ liệu COGS không? Hãy nêu một feature COGS lịch sử vẫn có thể dùng hợp lệ.

Câu 8 — Kiểm tra bảng feature sau khi tạo (2 điểm)

Sau bước feature engineering, pipeline tạo bảng sau để dự báo trước 28 ngày:

target_date	revenue_lag_7	revenue_lag_28	roll_mean_28_safe	day_of_week	is_promo
2022-12-01	4.800.000	4.100.000	3.920.000	3	1
2022-12-02	5.100.000	4.250.000	3.970.000	4	0

Các cột được tạo như sau:

Cột	Cách tính
revenue_lag_7	Revenue của 7 ngày trước target.
revenue_lag_28	Revenue của 28 ngày trước target.
roll_mean_28_safe	Trung bình Revenue từ (d-55) đến (d-28).
day_of_week	Thứ trong tuần của ngày target.
is_promo	Chương trình khuyến mãi đã được công bố trước ngày phát hành dự báo.

Cột nào gây data leakage? Giải thích dựa trên mốc thông tin (d-28).

Câu 9 — Kiểm tra tự động việc rò rỉ dữ liệu (8 điểm)

Hãy đề xuất một phép thử tự động để kiểm tra rằng feature lịch sử tại ngày (d) không sử dụng Revenue trong 27 ngày gần target.

Mô tả:

- Dữ liệu nào được cố ý thay đổi để thử pipeline.
- Feature nào được tính lại.
- Đại lượng nào được so sánh.
- Điều kiện pass/fail.

Câu 10 — Chia dữ liệu và chọn model theo thời gian (10 điểm)

Thiết kế quy trình expanding-window validation cho chuỗi doanh thu với (H=28).

1. Vì sao không được random split?

2. Vì sao cần chờ một khoảng cách ít nhất 28 ngày giữa phần dữ liệu dùng để huấn luyện và phần dùng để validation?
3. Nếu XGBoost thắng trung bình trên cross-validation nhưng LightGBM tốt hơn trên test cuối năm 2022, bạn chọn model nào và vì sao?

Câu 11 — Vì sao cần baseline và ablation? (8 điểm)

Nếu chỉ huấn luyện năm mô hình cây mà không so sánh với các quy tắc dự báo đơn giản:

1. Vì sao kết quả này chưa đủ thuyết phục team business?
2. Hãy đề xuất ít nhất hai baseline phù hợp.
3. Ablation theo nhóm feature trả lời câu hỏi khác gì so với feature importance?

Câu 12 — Đọc WAPE và bias (8 điểm)

LightGBM đạt:

- WAPE = 0,2038.
 - Bias = -0,1181.
 - Tập test gồm 184 ngày.
 - WAPE tốt hơn baseline 30,7%.
1. Vì sao dự án chọn WAPE thay vì chỉ dùng RMSE hoặc MAPE?
 2. Hãy diễn giải WAPE, bias và mức cải thiện so với baseline cho stakeholder.
 3. Nêu ít nhất hai kiểm tra cần làm trước khi kết luận model sẵn sàng triển khai.

Câu 13 — Giải thích model bằng TreeSHAP (8 điểm)

1. Global SHAP và local SHAP trả lời hai câu hỏi khác nhau như thế nào?
2. Việc bốn trong sáu feature quan trọng nhất liên quan đến mốc 364 ngày cho biết điều gì?
3. Vì sao dự án chuyển giá trị trung bình tuyệt đối của SHAP thành tỉ trọng phần trăm? Con số phần trăm này có ý nghĩa gì và không có ý nghĩa gì?
4. Vì sao cần gom các feature thành nhóm như lịch sử doanh thu, lịch, Tết và khuyến mãi? Khi các nhóm có số lượng feature khác nhau, vì sao phải xem cả tổng đóng góp của nhóm và đóng góp trung bình trên mỗi feature?
5. Hãy mô tả phép kiểm tính cộng tính để xác nhận SHAP giải thích đúng đầu ra model.
6. Vì sao SHAP không chứng minh quan hệ nhân quả?

Câu 14 — Prediction interval và cách sử dụng trong thực tế (8 điểm)

Conformal calibration cho kết quả:

- Target coverage: 90%.
- Empirical coverage: 92,4% — 170/184 ngày.
- Bán kính: 1.215.280 đồng.
- Độ rộng trung bình: 2.412.217 đồng.
- 15/184 ngày đi vào human-review queue.

1. Đánh giá interval có đạt mục tiêu không.
2. Vì sao chỉ nhìn coverage là chưa đủ?
3. Nếu các ngày nằm ngoài interval tập trung quanh đỉnh doanh thu, bạn sẽ cải tiến gì?
4. Đề xuất cách xử lý khi interval cắt ngưỡng 5 triệu đồng/ngày.

Câu hỏi mở rộng — Nhìn lại các quyết định của dự án

Các câu dưới đây không tính vào tổng 100 điểm. Chúng dùng để thảo luận thêm sau khi hoàn thành phần chính.

A. Cú giảm doanh thu năm 2019

Doanh thu trung bình năm 2019 giảm 38,6% so với giai đoạn trước. Hiện tượng này có thể ảnh hưởng thế nào đến việc chia dữ liệu, so sánh model và chất lượng dự báo? Ngoài quan sát biểu đồ, bạn sẽ kiểm tra gì để xác nhận đây là một thay đổi thật của thị trường?

B. Tách mùa vụ khỏi chênh lệch giữa các năm

Vì sao dự án phải chia Revenue mỗi ngày cho mức Revenue trung bình của năm đó trước khi so sánh doanh thu theo ngày trong tháng? Nếu bỏ bước này, ta có thể kết luận sai điều gì về ngày 31?

C. Khuyến mãi không chỉ là có hoặc không

Dự án gộp 50 chương trình khuyến mãi thành một số feature đơn giản. Cách làm này có thể bỏ mất những thông tin nào? Hãy đề xuất feature để model phân biệt loại khuyến mãi, ảnh hưởng trước và sau chương trình, và trường hợp khuyến mãi trùng với cuối tháng hoặc cận Tết.

D. Đưa model vào sử dụng an toàn

Vì sao không nên thay ngay quy tắc dự báo hiện tại bằng model mới? Hãy mô tả cách chạy thử song song, điều kiện quay về baseline và tín hiệu cho biết model cần được huấn luyện lại.
