

SEMINAR

Continual Learning

Phạm Thị Quỳnh Trang
Email: trangptq@vnu.edu.vn

Nội dung trình bày

01 Giới thiệu bài toán

Học máy truyền thống và Học máy liên tục (CL)

02 Các kịch bản học liên tục

Task-IL, Domain-IL, Class-IL

03 Thách thức chính

Catastrophic forgetting, Stability-Plasticity Dilemma

04 Các hướng tiếp cận

Regularization, Replay, Architecture, PTM-based

05 Đánh giá hiệu năng

Độ đo hiệu năng & Các bộ dữ liệu chuẩn

06 Xu hướng

Foundation models, LLM, hướng mở

01

Giới thiệu bài toán

Học máy truyền thống và Học máy liên tục (Continual Learning, CL)

Machine Learning truyền thống

- ▶ **Mô hình tĩnh:** Huấn luyện một lần trên toàn bộ tập dữ liệu cố định
- ▶ **Closed-world assumption:** Giả định phân phối dữ liệu không thay đổi sau khi huấn luyện
- ▶ **Quy trình thông thường:** Thu thập dữ liệu → Huấn luyện → Triển khai → Không cập nhật
- ▶ **Hoạt động tốt khi:** Dữ liệu đầy đủ, phân phối ổn định, bài toán không thay đổi theo thời gian
- ▶ **Hạn chế thực tế:** Thế giới thực luôn thay đổi: dữ liệu mới (phân bố mới), lớp mới, miền mới xuất hiện liên tục

Vấn đề trong thực tiễn



Tại sao không thể huấn luyện lại từ đầu?

- ▶ **Chi phí tính toán:** Huấn luyện lại toàn bộ dữ liệu tốn rất nhiều thời gian và tài nguyên
- ▶ **Dữ liệu cũ không khả dụng:** Quy định bảo mật, quyền riêng tư (GDPR), dữ liệu bị xóa hoặc quá lớn để lưu trữ
- ▶ **Dữ liệu đến liên tục (data stream):** Mô hình cần cập nhật ngay khi có dữ liệu mới mà không dừng hệ thống



Yêu cầu đặt ra:

- ▶ Học được tri thức mới mà không quên kiến thức cũ

Continual Learning (CL) là gì?

*Continual Learning (hay Lifelong Learning / Incremental Learning) là **một hướng tiếp cận thuật toán học (trong AI)** sao cho các mô hình học máy có thể **liên tục học** các tác vụ (task)/dữ liệu mới theo thời gian mà **không quên kiến thức đã học trước đó**, tương tự như cách con người học tập suốt đời.*

- ▶ **Mục tiêu:** Tích lũy tri thức theo thời gian, thích nghi với dữ liệu mới, tác vụ mới, và các khái niệm mới
- ▶ **Ràng buộc:** Không truy cập lại (hoặc hạn chế) dữ liệu cũ trong quá trình học
- ▶ **Thách thức cốt lõi:** Cân bằng giữa: Tính ổn định (stability) và Năng lực thích nghi (plasticity)

So sánh: ML truyền thống vs Continual Learning

Tiêu chí	ML truyền thống	Continual Learning
Dữ liệu huấn luyện	Toàn bộ, cố định một lần	Tuần tự, từng task/batch
Cập nhật mô hình	Không sau triển khai	Liên tục theo thời gian
Bộ nhớ dữ liệu cũ	Lưu trữ đầy đủ	Hạn chế hoặc không có
Vấn đề chính	Overfitting / underfitting	Catastrophic Forgetting
Ứng dụng	Bài toán tĩnh	Robot, NLP, Medical AI, ...

Ứng dụng thực tế của Continual Learning

- ▶ **Xử lý ngôn ngữ tự nhiên:** Học thêm ngôn ngữ/domain mới, cập nhật mô hình NER/RE khi có entity type mới
- ▶ **Computer Vision:** Nhận dạng đối tượng mới mà không quên lớp cũ, autonomous driving
- ▶ **Hệ thống gợi ý:** Cập nhật sở thích người dùng theo thời gian thực
- ▶ **Robot học tập:** Robot liên tục học kỹ năng mới trong môi trường thay đổi
- ▶ **Y tế và chẩn đoán:** Mô hình học thêm bệnh mới, phương pháp điều trị mới
- ▶ **An ninh mạng:** Phát hiện mối đe dọa mới trong khi duy trì khả năng phát hiện cũ

02

Các kịch bản học liên tục

Task-Incremental, Domain-Incremental, Class-Incremental Learning

Ba kịch bản chính trong Continual Learning

- ▶ **Task-Incremental Learning (Task-IL):** Task ID được cung cấp tại inference; mô hình biết đang làm tác vụ nào
- ▶ **Domain-Incremental Learning (Domain-IL):** Task ID không biết tại inference; input thay đổi nhưng output space giống nhau
- ▶ **Class-Incremental Learning (Class-IL):** **Khó nhất!** không biết task ID, số lớp (khái niệm) tăng dần, phải phân biệt lớp mới so với toàn bộ lớp đã học

Độ khó tăng dần: Task-IL < Domain-IL < Class-IL

Task-Incremental Learning (Task-IL)

Mô hình học lần lượt từng task $t_1, t_2, \dots, t_n$. Tại thời điểm inference, task identity được cung cấp (mô hình được biết task ID). Mô hình chỉ cần phân loại trong không gian output của task đó.

- ▶ **Ví dụ:** Task 1: phân loại chó/mèo; Task 2: phân loại xe/máy bay — biết task tại test time
- ▶ **Đặc điểm:** Dễ nhất trong 3 kịch bản; có thể dùng **head** phân loại riêng cho mỗi task
- ▶ **Hạn chế:** Không thực tế trong nhiều ứng dụng khi task ID không biết trước

Domain-Incremental Learning (Domain-IL)

Output space không thay đổi qua các task, nhưng phân phối input (domain) thay đổi. Tại inference, task/domain ID không được cung cấp, mô hình tự phải xử lý.

- ▶ **Ví dụ:** Phân loại cảm xúc (sentiment) trên các domain: phim ảnh → nhà hàng → sản phẩm điện tử
- ▶ **Đặc điểm:** Cùng kiến trúc output nhưng phân phối dữ liệu, đặc trưng thay đổi liên tục
- ▶ **Thách thức:** Mô hình cần thích nghi với domain shift mà không quên domain trước

Class-Incremental Learning (Class-IL)

Số lớp (khái niệm) tăng dần theo thời gian. Tại inference, task ID không biết và mô hình phải phân loại trong toàn bộ không gian lớp/khái niệm đã học từ trước đến nay.

- ▶ **Ví dụ:** Task 1: học lớp $\{0,1\}$; Task 2: học lớp $\{2,3\}$; Test: phân biệt tất cả $\{0,1,2,3,\dots\}$
- ▶ **Thách thức đặc biệt:** Mô hình bị lệch về các lớp/khái niệm mới (recency bias), quên đặc trưng lớp cũ
- ▶ **Thực tế:** Phổ biến nhất trong ứng dụng: nhận dạng khuôn mặt, phân loại sản phẩm mới

Cài đặt thực nghiệm chuẩn

- ▶ **Luồng dữ liệu:** $D = \{D_1, D_2, \dots, D_T\}$ — mỗi D_t chỉ truy cập được trong giai đoạn t
- ▶ **Mục tiêu tối ưu:** Tối thiểu hóa loss trên tất cả task đã học: $\min \sum L(f_\theta; D_t)$
- ▶ **Ràng buộc bộ nhớ:** Memory buffer M có giới hạn; mỗi task chỉ được lưu $|M|$ mẫu
- ▶ **Đánh giá:** Test trên tất cả task đã thấy; không được dùng dữ liệu task hiện tại để test task cũ
- ▶ **Upper bound:** Joint Training — huấn luyện trên tất cả dữ liệu cùng lúc (oracle)
- ▶ **Lower bound:** Fine-tuning — chỉ huấn luyện trên task mới

03

Các thách thức chính

Catastrophic Forgetting và Stability-Plasticity Dilemma

Quên nghiêm trọng (Catastrophic Forgetting)

Khi mô hình học sâu học tác vụ mới, trọng số (mô hình) được cập nhật theo gradient của dữ liệu mới. Điều này ghi đè lên các trọng số quan trọng cho task cũ, khiến hiệu năng trên tác vụ cũ giảm đột ngột, vấn đề này được gọi là Quên nghiêm trọng (Catastrophic Forgetting) (McCloskey & Cohen, 1989).

- ▶ **Nguyên nhân sâu xa:** Tham số được chia sẻ (shared parameters) giữa các task; gradient update phá vỡ những gì đã được học (tối ưu) trước đó.
- ▶ **Mức độ nghiêm trọng:** Fine-tuning đơn giản có thể khiến accuracy task cũ giảm từ >90% xuống <10%
- ▶ **Khác với con người:** Não người có cơ chế synaptic consolidation - tách biệt bộ nhớ ngắn hạn và dài hạn

Ví dụ minh họa quên nghiêm trọng

Kịch bản: Học tuần tự Task A → Task B

- ▶ **Bước 1 – Học Task A:** Mô hình đạt 95% accuracy trên Task A (phân loại chó/mèo)
- ▶ **Bước 2 – Học Task B:** Fine-tune trên Task B (phân loại xe/máy bay), đạt 93% accuracy
- ▶ **Bước 3 – Đánh giá lại Task A:** Accuracy Task A giảm xuống còn 12% , gần như quên hoàn toàn!

Tại sao xảy ra?

- ▶ Gradient descent trên Task B thay đổi trọng số theo hướng tối ưu cho B
- ▶ Các trọng số quan trọng cho A bị ghi đè không có cơ chế bảo vệ

Nghịch lý Stability-Plasticity

Stability (Ổn định)

Duy trì kiến thức cũ

- Không quên task đã học
- Bảo toàn trọng số quan trọng
- Tránh ghi đè đặc trưng cũ



Plasticity (Thích nghi)

Tiếp thu kiến thức mới

- Học nhanh task mới
- Cập nhật trọng số tự do
- Thích nghi phân phối mới

Tăng stability → giảm plasticity (và ngược lại)

Các thách thức khác trong Học liên tục

- ▶ **Task boundary không rõ ràng:** Trong thực tế, ranh giới giữa các task thường mờ nhạt hoặc không xác định
- ▶ **Dữ liệu mất cân bằng:** Task mới có ít mẫu hơn; mô hình bị lệch về task mới (recency bias)
- ▶ **Task identity không biết:** Đặc biệt khó trong Class-IL: không có thông tin task ID tại lúc test
- ▶ **Memory constraint:** Bộ nhớ lưu exemplar hữu hạn; cần chọn mẫu đại diện thông minh
- ▶ **Forward & Backward Transfer:** Học task mới có thể ảnh hưởng (tốt hoặc xấu) tới task cũ và task tương lai
- ▶ **Đánh giá công bằng:** Cần phương thức thực nghiệm đúng đắn để tránh so sánh không công bằng

Forward Transfer và Backward Transfer

Backward Transfer (BWT)

- ▶ **Định nghĩa:** Mức độ thay đổi hiệu suất trên task cũ sau khi học task mới
- ▶ **BWT âm:** Hiệu suất task cũ giảm → Catastrophic Forgetting
- ▶ **BWT dương:** Hiệu suất task cũ tăng → task mới giúp tổng quát hóa (hiếm)

Forward Transfer (FWT)

- ▶ **Định nghĩa:** Khả năng kiến thức đã học hỗ trợ việc học task mới nhanh hơn
- ▶ **FWT cao:** Mô hình học task mới nhanh hơn nhờ tái sử dụng kiến thức cũ

04

Các hướng tiếp cận

Regularization · Replay · Architecture · Knowledge Transfer · PTM-based

Các phương pháp học liên tục

- ▶ **Regularization-based:** Ràng buộc trọng số quan trọng không bị thay đổi nhiều khi học task mới
- ▶ **Replay-based:** Lưu trữ một phần dữ liệu cũ (exemplar) hoặc sinh lại dữ liệu để ôn tập
- ▶ **Architecture-based:** Mở rộng hoặc phân tách kiến trúc mạng cho từng task
- ▶ **Knowledge Transfer-based:** Chuyển cất tri thức từ mô hình cũ sang mô hình mới
- ▶ **PTM-based (Pre-trained Model):** Tận dụng mô hình lớn được huấn luyện trước (CLIP, ViT, LLM) làm backbone cố định hoặc fine-tune có kiểm soát

Regularization-based Methods

- ▶ **Ý tưởng cốt lõi:** Thêm penalty term vào loss function để bảo vệ trọng số quan trọng

Các phương pháp tiêu biểu:

- ▶ **EWC (Elastic Weight Consolidation):** Dùng Fisher Information Matrix ước lượng tầm quan trọng của từng tham số
- ▶ **SI (Synaptic Intelligence):** Tích lũy tầm quan trọng trong quá trình học, không cần tính Fisher
- ▶ **MAS (Memory Aware Synapses):** Tầm quan trọng dựa trên độ nhạy của output với sự biến thiên của trọng số
- ▶ **Ưu điểm:** Không cần lưu dữ liệu cũ; hiệu quả bộ nhớ cao
- ▶ **Hạn chế:** Không mở rộng tốt với nhiều task; không đủ mạnh cho Class-IL

Elastic Weight Consolidation (EWC)

Sau khi học Task A, EWC ước lượng tầm quan trọng của mỗi tham số θ_i bằng Fisher Information F_i . Khi học Task B, thêm penalty: $L(\theta) = L_B(\theta) + \lambda \sum_i F_i(\theta_i - \theta_i^*)^2$ để giữ các tham số quan trọng gần giá trị cũ θ^* .

- ▶ **Fisher Information:** $F_i = E[(\partial \log p(y|x, \theta) / \partial \theta_i)^2]$ đo độ cong của loss landscape
- ▶ **λ (lambda):** Siêu tham số điều chỉnh mức độ bảo vệ; λ cao $\rightarrow$ stability, λ thấp $\rightarrow$ plasticity
- ▶ **Vấn đề:** Khi số task tăng, số penalty tăng; approximation Fisher không chính xác với task phức tạp

Replay-based Methods

- ▶ **Ý tưởng cốt lõi:** Giữ lại một tập nhỏ dữ liệu cũ (exemplar memory) và ôn tập khi học task mới

Hai nhánh chính:

- ▶ **Experience Replay (ER):** Lưu trực tiếp các mẫu thực từ task cũ; replay trong mini-batch
- ▶ **Generative Replay (GR):** Dùng generative model (VAE, GAN) sinh giả dữ liệu của task cũ

Phương pháp tiêu biểu:

- ▶ **iCaRL, A-GEM, DER, MEMO, FOSTER:** Các biến thể cải tiến chiến lược replay và quản lý memory buffer
- ▶ **Ưu/nhược điểm:** Hiệu quả cao nhất trong Class-IL; nhưng cần bộ nhớ lưu exemplar, risk privacy

iCaRL – Incremental Classifier and Representation Learning

iCaRL (Rebuffi et al., 2017) kết hợp (1) Herding-based exemplar selection để chọn mẫu đại diện điển hình cho mỗi lớp, (2) Knowledge distillation để bảo toàn output của mô hình cũ, và (3) Nearest-mean-of-exemplars để phân loại.

- ▶ **Exemplar selection:** Chọn p mẫu có mean feature gần nhất với class mean (sử dụng herding algorithm)
- ▶ **Distillation loss:** BCE giữa output logit mới và cũ cho các lớp đã học
- ▶ **Hạn chế:** Feature drift: feature extractor thay đổi làm exemplar cũ kém đại diện theo thời gian

Architecture-based Methods

- ▶ **Ý tưởng cốt lõi:** Phân tách hoặc mở rộng kiến trúc mạng để tránh ảnh hưởng giữa các task

Các chiến lược:

- ▶ **Progressive Networks:** Thêm cột mới cho mỗi task; kết nối lateral với các cột cũ (cố định)
- ▶ **PackNet / HAT:** Pruning để tìm subnetwork riêng cho mỗi task trong cùng một mạng
- ▶ **DEN / PNN:** Tự động mở rộng capacity khi task mới đến
- ▶ **Parameter Isolation:** Cấp phát tham số chuyên biệt (dedicated parameters) cho mỗi task
- ▶ **Ưu/nhược điểm:** Không có forgetting lý thuyết; nhưng kích thước mô hình (số lượng tham số) tăng nhanh, không khả mở tốt

Knowledge Transfer & Distillation

- ▶ **Ý tưởng:** Dùng mô hình cũ (teacher) để hướng dẫn mô hình mới (student) bảo toàn kiến thức
 - ▶ **LwF (Learning without Forgetting):** Chứng cất tri thức từ output logit của teacher; không cần lưu dữ liệu cũ
 - ▶ **PODNet:** Chứng cất tri thức trên intermediate feature maps (pooled outputs) để giảm forgetting đặc trưng
 - ▶ **DER / DER++:** Kết hợp replay và distillation; lưu logit của task cũ cùng với exemplar
 - ▶ **FOSTER / MEMO:** Mở rộng feature extractor + distillation từ feature space cũ sang mới
 - ▶ **Ưu điểm:** Không cần dữ liệu gốc; hiệu quả khi kết hợp với replay

Pre-trained Model (PTM) based Methods

Các PTM lớn (ViT, CLIP, GPT) đã học được đặc trưng rất tốt; CL chỉ cần tinh chỉnh nhỏ để thích nghi với tác vụ mới

Các hướng tiếp cận:

- ▶ **Prompt-based (L2P, DualPrompt, CODA-Prompt):** Học prompt vector cho từng task; backbone ViT cố định hoàn toàn
- ▶ **Adapter-based (S-Prompts, EASE):** Thêm adapter nhỏ cho từng task; hiệu quả tham số cao
- ▶ **LoRA-based (O-LoRA, SO-LoRA):** Học low-rank update; orthogonality constraint để tránh interference
- ▶ **Feature-based (SimpleCIL, CLIP-based):** Cố định backbone; chỉ học classifier head trên frozen feature
- ▶ **Ưu điểm vượt trội:** Kết quả tốt hơn nhiều phương pháp truyền thống với ít tham số cần huấn luyện

Prompt-based Continual Learning

Thay vì tinh chỉnh toàn bộ mô hình, Prompt-based CL học thêm các token prompt $P = [p_1, p_2, \dots, p_n]$ được ghép vào input của Vision Transformer. Backbone ViT hoàn toàn cố định; chỉ các lời nhắc được cập nhật, tránh quên một cách tự nhiên.

- ▶ **L2P (Learning to Prompt):** Prompt pool chia sẻ; key-query matching chọn prompt theo input
- ▶ **DualPrompt:** G-Prompt (shared) + E-Prompt (task-specific); tách biệt kiến thức chung và riêng
- ▶ **Hạn chế:** Phụ thuộc nặng vào chất lượng pretrained backbone; cần task ID trong một số biến thể

LoRA-based Continual Learning

LoRA (Low-Rank Adaptation) phân rã cập nhật trọng số: $\Delta W = BA$, trong đó $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ với $r \ll d$. Trong CL, mỗi task học một cặp (B_i, A_i) riêng biệt hoặc chia sẻ có kiểm soát.

- ▶ **O-LoRA:** Ràng buộc orthogonality giữa các LoRA modules của các task khác nhau để giảm interference
- ▶ **SO-LoRA / SimO-LoRA:** Sparse orthogonal basis; học nhiều hướng tối ưu độc lập cho mỗi task
- ▶ **Ưu điểm:** Rất hiệu quả tham số; kết hợp tốt với LLM và ViT; dễ mở rộng

05

Đánh giá hiệu năng học liên tục

Metrics đánh giá · Bộ dữ liệu chuẩn · Protocol thực nghiệm

Các độ đo đánh giá

- ▶ **Average Accuracy (ACC):** Trung bình accuracy trên tất cả task đã học: $ACC = (1/T) \sum_{\square} a_{\square, T}$
- ▶ **Backward Transfer (BWT):** $BWT = (1/T-1) \sum_{\square} (a_{\square, T} - a_{\square, t})$; âm: forgetting, dương: beneficial transfer
- ▶ **Forward Transfer (FWT):** $FWT = (1/T-1) \sum_{\square} (a_{\square, t} - \tilde{b}_{\square})$; so với baseline zero-shot
- ▶ **Forgetting Measure (FM):** $FM = (1/T-1) \sum_{\square} \max_{\{k \leq t\}} (a_{\square, k} - a_{\square, T})$
- ▶ **Intransigence (I):** Đo khả năng học task mới; cao khi mô hình quá stable

Các tập dữ liệu chuẩn

Computer Vision:

- ▶ **Split-CIFAR-10/100:** CIFAR chia thành 5 task (2/20 class mỗi task); chuẩn phổ biến nhất
- ▶ **Split-TinyImageNet:** 200 class chia thành 10 task; phức tạp hơn CIFAR
- ▶ **Permuted / Rotated MNIST:** Domain-IL kinh điển; pixel permutation/rotation tạo domain mới

NLP:

- ▶ **CORe50:** Object recognition liên tục trong môi trường robot thực tế
- ▶ **Continual NER / RE datasets:** Entity type mới, relation type mới thêm dần theo task

So sánh các nhóm phương pháp

Phương pháp	Bộ nhớ data	Tham số thêm	Class-IL	Hiệu quả
Regularization	Không	Thấp	Kém	★★
Replay (ER)	Có (nhỏ)	Thấp	Tốt	★★★★
Architecture	Không	Cao	Tốt	★★★
Distillation	Không	Trung bình	Tốt	★★★
PTM-based	Không/Ít	Rất thấp	Rất tốt	★★★★★

06

Xu hướng

Foundation Models · LLM · Hướng nghiên cứu mở

Xu hướng hiện tại (2023–2025)

- ▶ **CL với Large Language Models (LLM):** Quên nghiêm trọng trong tinh chỉnh LLM; PEFT (LoRA, Adapter) + CL
- ▶ **CL với Vision-Language Models:** CLIP-based CL: tận dụng text-image alignment để chống quên
- ▶ **Online Continual Learning:** Mỗi ví dụ dữ liệu chỉ được thấy một lần; thách thức tốc độ và bộ nhớ
- ▶ **Federated Continual Learning:** Học liên tục trong môi trường phân tán, bảo mật dữ liệu cục bộ
- ▶ **Exemplar-free Class-IL:** Không lưu dữ liệu cũ; dùng prototype/statistics thay thế
- ▶ **Multi-modal CL:** Học liên tục trên nhiều mô thức: ảnh, văn bản, âm thanh cùng lúc

Các thách thức nghiên cứu còn mở

- ▶ **Task-agnostic CL:** Không có task boundary rõ ràng, không biết khi nào tác vụ thay đổi
- ▶ **Scalability:** Hiệu suất với hàng trăm, hàng nghìn task liên tiếp
- ▶ **Negative transfer:** Task mới làm giảm khả năng học task tương lai (negative FWT)
- ▶ **Đánh giá thực tế hơn:** Bộ dữ liệu chuẩn gần với ứng dụng thực: imbalanced data, noisy label, long-tail
- ▶ **Theory của CL:** Hiểu biết lý thuyết về điều kiện đủ để tránh quên nghiêm trọng
- ▶ **Privacy-preserving CL:** CL khi không được phép lưu bất kỳ dữ liệu cũ nào (GDPR compliance)

Hướng nghiên cứu của nhóm

- ▶ **Memory-based Replay cho NLP:** ProtoAug, ELI cải tiến exemplar selection và augmentation cho Relation Extraction
- ▶ **Knowledge Transfer**
CL-plugin, ZeroRFF: chắc lọc tri thức và zero-shot transfer
- ▶ **Adaptive Architecture**
DAKTA, OPE/APF, SO-LoRA: kiến trúc thích ứng với sparse orthogonal LoRA
- ▶ **Vision CL**
FOCAL/BiMoE: Multi-domain Incremental Learning với iFFT và Mixture-of-Experts
- ▶ **Vision-Language CL**
SMH (Statistical Memory Head): CLIP-based Class-Incremental Learning

Các công bố cùng thành viên AI VN

Lê Văn Trường (AIO2024 - SOICT2025, MAPR2025)

Trần Ngọc Việt Anh (AIO2024 - ICPR2026)

Phạm Lê Huy (AIO2023 - ACIIDS2024)

Mạc Quang Đạt (AIO2025 - KSE2025, ICME2026)

Nguyễn Quốc Hiệu (AIO2025 - ACMMM2026(Submitted))

Đặng Minh Anh (AIO2024 - RIVF 2024)

Tổng kết

- 1 Học liên tục tiếp cận giải quyết việc học (máy) liên tục mà không quên; thách thức cốt lõi của AI trong thế giới thực.
- 2 Quên nghiêm trọng và Nghịch lý giữa tính ổn định - khả năng thích nghi là hai vấn đề trung tâm cần giải quyết.
- 3 4 nhóm phương pháp chính: Regularization, Replay, Architecture, Distillation; mỗi nhóm có ưu/nhược điểm riêng.
- 4 PTM-based methods (Prompt, Adapter, LoRA) là xu hướng mạnh nhất hiện tại nhờ tận dụng các mô hình nền tảng được huấn luyện trước.
- 5 Nhiều thách thức vẫn còn mở: task-agnostic CL, scalability, privacy, lý thuyết nền tảng.

Tài liệu tham khảo chính

- [1] Kirkpatrick et al. (2017). Overcoming catastrophic forgetting in neural networks. PNAS.
- [2] Rebuffi et al. (2017). iCaRL: Incremental Classifier and Representation Learning. CVPR.
- [3] Wang et al. (2022). Learning to Prompt for Continual Learning. CVPR.
- [4] Wang et al. (2024). A Comprehensive Survey of Continual Learning. IEEE TPAMI.
- [5] Masana et al. (2023). Class-Incremental Learning Survey. IEEE TPAMI.
- [6] De Lange et al. (2022). A Continual Learning Survey: Defying Forgetting. IEEE TPAMI.
- [7] Dong et al. (2023). FOSTER: Feature Boosting and Compression for CIL. ECCV.
- [8] Zhou et al. (2023). Revisiting Class-Incremental Learning with Pre-Trained Models. TPAMI.